

Corrigé du Sujet d'Entraînement n°1 : Statistiques à une variable

Préparation au CAPES de Mathématiques

Correction détaillée et commentaires pédagogiques

Session 2025-2026

Exercice 1 : Questions de cours (Démonstrations fondatrices)

1. Propriété de moindre carré de la moyenne

(a) Soit $\theta \in \mathbb{R}$. Développons le terme général sous la somme de la fonction g :

$$g(\theta) = \sum_{i=1}^k n_i (x_i - \theta)^2 = \sum_{i=1}^k n_i (x_i^2 - 2\theta x_i + \theta^2)$$

Par linéarité de la sommation, on sépare l'expression en trois sommes distinctes et on extrait les facteurs constants par rapport à l'indice i :

$$g(\theta) = \sum_{i=1}^k n_i x_i^2 - 2\theta \sum_{i=1}^k n_i x_i + \theta^2 \sum_{i=1}^k n_i$$

En utilisant les relations fondamentales du cours :

- $\sum_{i=1}^k n_i = N$ (effectif total)
- $\sum_{i=1}^k n_i x_i = N\bar{x}$ (par définition de la moyenne $\bar{x} = \frac{1}{N} \sum_{i=1}^k n_i x_i$)

On obtient l'expression polynomiale en θ recherchée :

$$g(\theta) = N\theta^2 - 2N\bar{x}\theta + \sum_{i=1}^k n_i x_i^2$$

C'est un polynôme du second degré de la forme $A\theta^2 + B\theta + C$ avec :

$$A = N \quad , \quad B = -2N\bar{x} \quad , \quad C = \sum_{i=1}^k n_i x_i^2$$

(b) Le coefficient $A = N$ est strictement positif ($N \in \mathbb{N}^*$). La fonction polynomiale g est donc strictement convexe et admet un unique minimum global sur $\mathbb{R}$. Ce minimum est atteint au sommet de la parabole, soit en :

$$\theta_0 = -\frac{B}{2A} = -\frac{-2N\bar{x}}{2N} = \bar{x}$$

Ainsi, la fonction g atteint son minimum global unique en $\theta = \bar{x}$.

- (c) **Interprétation géométrique/intuitive :** Le terme $(x_i - \theta)^2$ représente le carré de la distance euclidienne entre une valeur de la série et un paramètre central θ . Minimiser la somme de ces carrés revient à chercher le point θ « le plus proche » de toutes les données au sens de la distance quadratique. La moyenne est donc le centre de gravité (ou barycentre) de la distribution.

2. Optimisation en valeur absolue et médiane

- (a) La fonction $h(\theta) = \sum_{i=1}^N |x_i - \theta|$ est une somme de fonctions de la forme $\theta \mapsto |x_i - \theta|$. Chacune de ces fonctions est continue sur $\mathbb{R}$ et affine par morceaux (linéaire de pente -1 si $\theta < x_i$ et de pente $+1$ si $\theta > x_i$). Par somme de fonctions ayant ces propriétés, h est continue, affine par morceaux et convexe sur $\mathbb{R}$.
- (b) Soit $\theta \notin \{x_1, \dots, x_N\}$. La fonction valeur absolue est dérivable partout sauf en 0. Donc h est dérivable en θ . Pour chaque $i \in \{1, \dots, N\}$:
- Si $x_i < \theta$, alors $|x_i - \theta| = \theta - x_i$, de dérivée par rapport à θ égale à 1.
 - Si $x_i > \theta$, alors $|x_i - \theta| = x_i - \theta$, de dérivée par rapport à θ égale à -1 .

On en déduit que la dérivée $h'(\theta)$ vaut :

$$h'(\theta) = \sum_{i=1}^N \text{sgn}(\theta - x_i) = \text{card}(\{i / x_i < \theta\}) - \text{card}(\{i / x_i > \theta\})$$

Autrement dit, la dérivée en un point correspond au nombre de données situées à gauche de θ moins le nombre de données situées à droite de θ .

- (c) Posons $N = 2p + 1$. La série étant ordonnée, la médiane unique au sens pratique est $M_e = x_{p+1}$. Étudions le signe de $h'(\theta)$ sur les intervalles ouverts délimités par les valeurs distinctes :
- **Si $\theta < M_e = x_{p+1}$:** θ est situé avant la valeur d'indice $p+1$. Le nombre de données inférieures à θ est au maximum p , tandis que le nombre de données supérieures à θ est au moins $p + 1$. Dès lors, $\text{card}(\{i / x_i < \theta\}) < \text{card}(\{i / x_i > \theta\})$, d'où $h'(\theta) < 0$. La fonction h est strictement décroissante sur $] -\infty; M_e[$.
 - **Si $\theta > M_e = x_{p+1}$:** Par un raisonnement symétrique, le nombre de données situées à gauche de θ est au moins $p + 1$ et à droite au plus p . On a $\text{card}(\{i / x_i < \theta\}) > \text{card}(\{i / x_i > \theta\})$, d'où $h'(\theta) > 0$. La fonction h est strictement croissante sur $]M_e; +\infty[$.

Par continuité de h , la fonction décroît strictement jusqu'en M_e puis croît strictement après M_e . Le minimum global unique de h est donc bien atteint en la médiane $\theta = M_e$.

Exercice 2 : Effets de transformations affines et indicateurs robustes

1. Harmonisation par translation et dilatation ($Y = 1,2X + 1$)

(a) Par linéarité de la moyenne :

$$\bar{y} = 1,2\bar{x} + 1 = 1,2 \times 9,5 + 1 = 11,4 + 1 = 12,4$$

Pour l'écart-type, l'indicateur de dispersion est insensible à la translation ($b = 1$) et multiplié par le coefficient d'échelle $a = 1,2$:

$$\sigma(Y) = 1,2 \times \sigma(X) = 1,2 \times 2,4 = 2,88$$

Interprétation : La moyenne augmente de près de 3 points, ce qui rehausse le niveau global. Cependant, l'écart-type augmente également ($\sigma(Y) > \sigma(X)$), ce qui montre que la transformation a « étiré » les notes et accru les écarts mutuels entre les candidats.

(b) Le coefficient multiplicateur $a = 1,2$ étant strictement positif, l'ordre des données est conservé. La médiane subit directement la transformation affine :

$$M_e(Y) = 1,2 \times M_e(X) + 1 = 1,2 \times 9 + 1 = 11,8$$

Justification rigoureuse : Par définition, au moins 50% des individus ont une note $X \leq 9$. Comme l'application $t \mapsto 1,2t + 1$ est strictement croissante, l'inégalité $X \leq 9$ équivaut à $1,2X + 1 \leq 1,2 \times 9 + 1$, c'est-à-dire $Y \leq 11,8$. Ainsi, au moins 50% des individus vérifient $Y \leq 11,8$. Le même raisonnement s'applique pour la condition $Y \geq 11,8$.

Pour l'écart interquartile $I_Q(Y)$, les indicateurs de dispersion ne dépendent pas de la translation :

$$I_Q(Y) = Q_3(Y) - Q_1(Y) = (1,2Q_3(X) + 1) - (1,2Q_1(X) + 1) = 1,2 \times I_Q(X)$$

Or $I_Q(X) = Q_3(X) - Q_1(X) = 11,5 - 7,5 = 4$. Donc :

$$I_Q(Y) = 1,2 \times 4 = 4,8$$

2. Cas d'un coefficient multiplicateur négatif ($Z = -0,5X + 20$)

(a) **Démonstration générale :** Soit $Y = aX + b$ avec $a < 0$. On sait que $\bar{y} = a\bar{x} + b$. Par définition de la variance :

$$V(Y) = \frac{1}{N} \sum_{i=1}^k n_i (y_i - \bar{y})^2$$

En substituant $y_i = ax_i + b$ et $\bar{y} = a\bar{x} + b$:

$$y_i - \bar{y} = (ax_i + b) - (a\bar{x} + b) = a(x_i - \bar{x})$$

En élevant au carré : $(y_i - \bar{y})^2 = a^2(x_i - \bar{x})^2$. Par linéarité de la somme :

$$V(Y) = \frac{1}{N} \sum_{i=1}^k n_i a^2 (x_i - \bar{x})^2 = a^2 \left(\frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{x})^2 \right) = a^2 V(X)$$

En passant à la racine carrée, puisque $\sqrt{a^2} = |a|$:

$$\sigma(Y) = \sqrt{V(Y)} = \sqrt{a^2 V(X)} = |a| \sqrt{V(X)} = |a| \sigma(X)$$

(b) Pour la série Z , $a = -0,5$. On a donc :

$$\sigma(Z) = |-0,5| \times \sigma(X) = 0,5 \times 2,4 = 1,2$$

(c) L'application $t \mapsto -0,5t + 20$ est strictement décroissante car son coefficient directeur est négatif. Par conséquent, elle renverse l'ordre des données. Les plus petites notes initiales deviennent les plus grandes notes transformées et vice-versa. Les rôles des quartiles s'échangent donc :

$$— Q_1(Z) = -0,5 \times Q_3(X) + 20 = -0,5 \times 11,5 + 20 = -5,75 + 20 = 14,25$$

$$— Q_3(Z) = -0,5 \times Q_1(X) + 20 = -0,5 \times 7,5 + 20 = -3,75 + 20 = 16,25$$

Exercice 3 : Fusion de populations et formule de König-Huygens

1. Analyse globale de position

(a) L'effectif total de la population fusionnée est $N = N_1 + N_2 = 60 + 40 = 100$. La moyenne globale $\bar{x}$ est donnée par la moyenne pondérée des moyennes de chaque groupe :

$$\bar{x} = \frac{N_1\bar{x}_1 + N_2\bar{x}_2}{N_1 + N_2} = \frac{60 \times 25 + 40 \times 35}{100} = \frac{1500 + 1400}{100} = \frac{2900}{100} = 29 \text{ min}$$

(b) La moyenne arithmétique simple de $\bar{x}_1$ et $\bar{x}_2$ vaut $\frac{25+35}{2} = 30$ min. La moyenne globale (29 min) n'est pas égale à cette moyenne simple car les deux sous-populations possèdent des effectifs différents ($N_1 \neq N_2$). La formule de la moyenne globale montre qu'il s'agit d'un barycentre où chaque sous-population est pondérée par son effectif (le groupe A, plus nombreux, « attire » légitimement la moyenne globale vers sa propre moyenne de 25 min).

2. Analyse globale de dispersion

(a) D'après la formule de König-Huygens appliquée au Groupe A, on a $V_1 = M_A - \bar{x}_1^2$, soit $\sigma_1^2 = M_A - \bar{x}_1^2$. On en isole la moyenne des carrés M_A :

$$M_A = \sigma_1^2 + \bar{x}_1^2 = 4^2 + 25^2 = 16 + 625 = 641$$

(b) De la même manière pour le Groupe B :

$$M_B = \sigma_2^2 + \bar{x}_2^2 = 6^2 + 35^2 = 36 + 1225 = 1261$$

(c) La moyenne des carrés pour la population totale, notée M_{tot} , s'obtient en effectuant la moyenne pondérée des moyennes des carrés de chaque sous-population (car la somme totale des carrés est la somme des carrés du Groupe A et du Groupe B) :

$$M_{\text{tot}} = \frac{N_1 M_A + N_2 M_B}{N_1 + N_2} = \frac{60 \times 641 + 40 \times 1261}{100}$$

$$M_{\text{tot}} = \frac{38460 + 50440}{100} = \frac{88900}{100} = 889$$

- (d) Appliquons de nouveau la formule de König-Huygens sur la population globale pour déterminer la variance globale V :

$$V = M_{\text{tot}} - \bar{x}^2 = 889 - 29^2$$

Or $29^2 = 841$. Donc :

$$V = 889 - 841 = 48$$

L'écart-type global σ est la racine carrée de la variance globale :

$$\sigma = \sqrt{V} = \sqrt{48} = 4\sqrt{3} \approx 6,93 \text{ min}$$

Commentaire : On remarque que l'écart-type global ($\sigma \approx 6,93$ min) est strictement supérieur à σ_1 (4 min) et à σ_2 (6 min). Cela s'explique par le fait que la dispersion globale prend en compte non seulement la dispersion interne à chaque groupe (variabilité intra-classe), mais s'y ajoute l'écart entre les moyennes des deux groupes (variabilité inter-classe, due au décalage important entre 25 min et 35 min).