

Sujet d'Entraînement n°1 : Statistiques à une variable

Préparation au CAPES de Mathématiques

Séries statistiques quantitatives, caractéristiques de position et de dispersion

Session 2026-2027

Ce sujet est conçu dans l'esprit des épreuves écrites du CAPES. Il demande de la rigueur dans les justifications mathématiques, une bonne maîtrise des définitions fondamentales et des capacités d'interprétation et de démonstration.

L'usage de la calculatrice en mode examen est autorisé.

Questions de cours

Le candidat est invité à démontrer deux théorèmes d'optimisation essentiels présentés dans le cours. Soit une population finie de cardinal $N \in \mathbb{N}^*$, et $(x_1, x_2, \dots, x_k)$ l'ensemble des valeurs distinctes ordonnées d'une série statistique quantitative, associées aux effectifs $(n_1, n_2, \dots, n_k)$.

1. Propriété de moindre carré de la moyenne

- (a) Soit la fonction $g : \theta \mapsto \sum_{i=1}^k n_i(x_i - \theta)^2$ définie pour $\theta \in \mathbb{R}$. Développer l'expression de $g(\theta)$ et montrer qu'elle peut s'écrire sous la forme d'un polynôme du second degré : $g(\theta) = A\theta^2 + B\theta + C$ où l'on déterminera les expressions de A , B et C en fonction de N , de la moyenne de la série $\bar{x}$ et de la somme des carrés des valeurs.
- (b) En déduire que la fonction g admet un minimum global unique atteint en $\theta = \bar{x}$.
- (c) Donner l'interprétation géométrique ou intuitive de ce résultat.

2. Optimisation en valeur absolue et médiane

Pour simplifier, on suppose ici que toutes les données de la série brute sont distinctes, de sorte que $k = N$ et $n_i = 1$ pour tout $i \in \{1, \dots, N\}$. Les valeurs sont triées : $x_1 < x_2 < \dots < x_N$. On considère la fonction $h : \theta \mapsto \sum_{i=1}^N |x_i - \theta|$.

- (a) Justifier brièvement que la fonction h est continue et affine par morceaux sur $\mathbb{R}$.
- (b) Pour $\theta \notin \{x_1, \dots, x_N\}$, exprimer la dérivée $h'(\theta)$ à l'aide de la fonction signe ou en dénombrant les valeurs de la série.
- (c) En supposant que N est impair ($N = 2p + 1$ avec $p \in \mathbb{N}$), étudier le signe de $h'(\theta)$ sur chacun des intervalles $]x_j; x_{j+1}[$. Démontrer alors que le minimum global de h est atteint uniquement en la médiane $M_e = x_{p+1}$.

Exercice 2 : Effets de transformations affines et indicateurs robustes

Lors d'un examen blanc de préparation, un échantillon de N correcteurs a attribué des notes à un lot de copies. On note X la variable statistique correspondant aux notes initiales. La série possède une moyenne $\bar{x} = 9,5$, un écart-type $\sigma(X) = 2,4$, une médiane $M_e(X) = 9$, un premier quartile $Q_1(X) = 7,5$ et un troisième quartile $Q_3(X) = 11,5$.

1. Harmonisation par translation et dilatation

Pour rehausser les résultats, le responsable de la formation applique la transformation affine suivante à l'ensemble des notes : $Y = 1,2X + 1$.

- Calculer la nouvelle moyenne $\bar{y}$ ainsi que le nouvel écart-type $\sigma(Y)$ de la série. Donner une interprétation de l'effet de cette transformation sur la dispersion des notes.
- Déterminer la nouvelle médiane $M_e(Y)$, ainsi que le nouvel écart interquartile $I_Q(Y)$. Justifier rigoureusement le calcul pour la médiane en utilisant sa définition.

2. Cas d'un coefficient multiplicateur négatif

On imagine maintenant qu'une erreur de barème a conduit à transformer les notes selon l'application affine $Z = -0,5X + 20$.

- Démontrer de manière générale à partir des définitions que si $Y = aX + b$ avec $a < 0$, alors la variance vérifie $V(Y) = a^2V(X)$ et l'écart-type vérifie $\sigma(Y) = |a|\sigma(X)$.
- En déduire l'écart-type $\sigma(Z)$ de cette nouvelle série.
- Déterminer les valeurs du premier quartile $Q_1(Z)$ et du troisième quartile $Q_3(Z)$. Expliquer pourquoi les rôles des quartiles se trouvent inversés.

Exercice 3 : Fusion de populations et formule de König-Huygens

Une étude statistique porte sur le temps de parcours (exprimé en minutes) des candidats pour se rendre à leur centre d'examen du CAPES. Les données ont été collectées auprès de deux groupes distincts issus de deux départements différents.

- **Groupe A** : Effectif $N_1 = 60$ candidats ; moyenne des temps $\bar{x}_1 = 25$ min ; écart-type $\sigma_1 = 4$ min.
- **Groupe B** : Effectif $N_2 = 40$ candidats ; moyenne des temps $\bar{x}_2 = 35$ min ; écart-type $\sigma_2 = 6$ min.

1. Analyse globale de position

- Calculer le temps moyen global $\bar{x}$ de l'ensemble des 100 candidats.
- Le temps moyen global est-il égal à la moyenne arithmétique simple de $\bar{x}_1$ et $\bar{x}_2$? Justifier la réponse en explicitant la notion de moyenne globale comme barycentre.

2. Analyse globale de dispersion

- À l'aide de la formule de König-Huygens, déterminer pour le Groupe A la moyenne des carrés des temps de parcours, c'est-à-dire la quantité $M_A = \frac{1}{N_1} \sum_{i \in A} x_i^2$.
- Calculer de même la moyenne des carrés des temps de parcours pour le Groupe B, soit $M_B = \frac{1}{N_2} \sum_{i \in B} x_i^2$.
- En déduire la moyenne des carrés des temps de parcours pour la population totale des 100 candidats.
- En appliquant de nouveau la formule de König-Huygens sur l'ensemble de la population, calculer la variance globale V puis l'écart-type global σ de cette série fusionnée. Commenter le résultat obtenu par rapport aux écarts-types initiaux σ_1 et σ_2 .

La page suivante comporte le corrigé de l'épreuve. Il est recommandé de tenter de résoudre les exercices avant de consulter les solutions proposées.

Exercice 1 : Questions de cours (Démonstrations fondatrices)

1. Propriété de moindre carré de la moyenne

(a) Soit $\theta \in \mathbb{R}$. Développons le terme général sous la somme de la fonction g :

$$g(\theta) = \sum_{i=1}^k n_i(x_i - \theta)^2 = \sum_{i=1}^k n_i(x_i^2 - 2\theta x_i + \theta^2)$$

Par linéarité de la sommation, on sépare l'expression en trois sommes distinctes et on extrait les facteurs constants par rapport à l'indice i :

$$g(\theta) = \sum_{i=1}^k n_i x_i^2 - 2\theta \sum_{i=1}^k n_i x_i + \theta^2 \sum_{i=1}^k n_i$$

En utilisant les relations fondamentales du cours :

- $\sum_{i=1}^k n_i = N$ (effectif total)
- $\sum_{i=1}^k n_i x_i = N\bar{x}$ (par définition de la moyenne $\bar{x} = \frac{1}{N} \sum_{i=1}^k n_i x_i$)

On obtient l'expression polynomiale en θ recherchée :

$$g(\theta) = N\theta^2 - 2N\bar{x}\theta + \sum_{i=1}^k n_i x_i^2$$

C'est un polynôme du second degré de la forme $A\theta^2 + B\theta + C$ avec :

$$A = N \quad , \quad B = -2N\bar{x} \quad , \quad C = \sum_{i=1}^k n_i x_i^2$$

(b) Le coefficient $A = N$ est strictement positif ($N \in \mathbb{N}^*$). La fonction polynomiale g est donc strictement convexe et admet un unique minimum global sur $\mathbb{R}$. Ce minimum est atteint au sommet de la parabole, soit en :

$$\theta_0 = -\frac{B}{2A} = -\frac{-2N\bar{x}}{2N} = \bar{x}$$

Ainsi, la fonction g atteint son minimum global unique en $\theta = \bar{x}$.

(c) **Interprétation géométrique/intuitive :** Le terme $(x_i - \theta)^2$ représente le carré de la distance euclidienne entre une valeur de la série et un paramètre central θ . Minimiser la somme de ces carrés revient à chercher le point θ « le plus proche » de toutes les données au sens de la distance quadratique. La moyenne est donc le centre de gravité (ou barycentre) de la distribution.

2. Optimisation en valeur absolue et médiane

(a) La fonction $h(\theta) = \sum_{i=1}^N |x_i - \theta|$ est une somme de fonctions de la forme $\theta \mapsto |x_i - \theta|$. Chacune de ces fonctions est continue sur $\mathbb{R}$ et affine par morceaux (linéaire de pente -1 si $\theta < x_i$ et de pente $+1$ si $\theta > x_i$). Par somme de fonctions ayant ces propriétés, h est continue, affine par morceaux et convexe sur $\mathbb{R}$.

- (b) Soit $\theta \notin \{x_1, \dots, x_N\}$. La fonction valeur absolue est dérivable partout sauf en 0. Donc h est dérivable en θ . Pour chaque $i \in \{1, \dots, N\}$:

- Si $x_i < \theta$, alors $|x_i - \theta| = \theta - x_i$, de dérivée par rapport à θ égale à 1.
- Si $x_i > \theta$, alors $|x_i - \theta| = x_i - \theta$, de dérivée par rapport à θ égale à -1 .

On en déduit que la dérivée $h'(\theta)$ vaut :

$$h'(\theta) = \sum_{i=1}^N \text{sgn}(\theta - x_i) = \text{card}(\{i / x_i < \theta\}) - \text{card}(\{i / x_i > \theta\})$$

Autrement dit, la dérivée en un point correspond au nombre de données situées à gauche de θ moins le nombre de données situées à droite de θ .

- (c) Posons $N = 2p + 1$. La série étant ordonnée, la médiane unique au sens pratique est $M_e = x_{p+1}$. Étudions le signe de $h'(\theta)$ sur les intervalles ouverts délimités par les valeurs distinctes :

- **Si** $\theta < M_e = x_{p+1}$: θ est situé avant la valeur d'indice $p+1$. Le nombre de données inférieures à θ est au maximum p , tandis que le nombre de données supérieures à θ est au moins $p+1$. Dès lors, $\text{card}(\{i / x_i < \theta\}) < \text{card}(\{i / x_i > \theta\})$, d'où $h'(\theta) < 0$. La fonction h est strictement décroissante sur $] -\infty; M_e[$.
- **Si** $\theta > M_e = x_{p+1}$: Par un raisonnement symétrique, le nombre de données situées à gauche de θ est au moins $p+1$ et à droite au plus p . On a $\text{card}(\{i / x_i < \theta\}) > \text{card}(\{i / x_i > \theta\})$, d'où $h'(\theta) > 0$. La fonction h est strictement croissante sur $]M_e; +\infty[$.

Par continuité de h , la fonction décroît strictement jusqu'en M_e puis croît strictement après M_e . Le minimum global unique de h est donc bien atteint en la médiane $\theta = M_e$.

Exercice 2 : Effets de transformations affines et indicateurs robustes

1. Harmonisation par translation et dilatation ($Y = 1,2X + 1$)

- (a) Par linéarité de la moyenne :

$$\bar{y} = 1,2\bar{x} + 1 = 1,2 \times 9,5 + 1 = 11,4 + 1 = 12,4$$

Pour l'écart-type, l'indicateur de dispersion est insensible à la translation ($b = 1$) et multiplié par le coefficient d'échelle $a = 1,2$:

$$\sigma(Y) = 1,2 \times \sigma(X) = 1,2 \times 2,4 = 2,88$$

Interprétation : La moyenne augmente de près de 3 points, ce qui rehausse le niveau global. Cependant, l'écart-type augmente également ($\sigma(Y) > \sigma(X)$), ce qui montre que la transformation a « étiré » les notes et accru les écarts mutuels entre les candidats.

- (b) Le coefficient multiplicateur $a = 1,2$ étant strictement positif, l'ordre des données est conservé. La médiane subit directement la transformation affine :

$$M_e(Y) = 1,2 \times M_e(X) + 1 = 1,2 \times 9 + 1 = 11,8$$

Justification rigoureuse : Par définition, au moins 50% des individus ont une note $X \leq 9$. Comme l'application $t \mapsto 1,2t + 1$ est strictement croissante, l'inégalité $X \leq 9$

équivalent à $1,2X + 1 \leq 1,2 \times 9 + 1$, c'est-à-dire $Y \leq 11,8$. Ainsi, au moins 50% des individus vérifient $Y \leq 11,8$. Le même raisonnement s'applique pour la condition $Y \geq 11,8$.

Pour l'écart interquartile $I_Q(Y)$, les indicateurs de dispersion ne dépendent pas de la translation :

$$I_Q(Y) = Q_3(Y) - Q_1(Y) = (1,2Q_3(X) + 1) - (1,2Q_1(X) + 1) = 1,2 \times I_Q(X)$$

Or $I_Q(X) = Q_3(X) - Q_1(X) = 11,5 - 7,5 = 4$. Donc :

$$I_Q(Y) = 1,2 \times 4 = 4,8$$

2. Cas d'un coefficient multiplicateur négatif ($Z = -0,5X + 20$)

- (a) **Démonstration générale :** Soit $Y = aX + b$ avec $a < 0$. On sait que $\bar{y} = a\bar{x} + b$. Par définition de la variance :

$$V(Y) = \frac{1}{N} \sum_{i=1}^k n_i (y_i - \bar{y})^2$$

En substituant $y_i = ax_i + b$ et $\bar{y} = a\bar{x} + b$:

$$y_i - \bar{y} = (ax_i + b) - (a\bar{x} + b) = a(x_i - \bar{x})$$

En élevant au carré : $(y_i - \bar{y})^2 = a^2(x_i - \bar{x})^2$. Par linéarité de la somme :

$$V(Y) = \frac{1}{N} \sum_{i=1}^k n_i a^2 (x_i - \bar{x})^2 = a^2 \left(\frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{x})^2 \right) = a^2 V(X)$$

En passant à la racine carrée, puisque $\sqrt{a^2} = |a|$:

$$\sigma(Y) = \sqrt{V(Y)} = \sqrt{a^2 V(X)} = |a| \sqrt{V(X)} = |a| \sigma(X)$$

- (b) Pour la série Z , $a = -0,5$. On a donc :

$$\sigma(Z) = |-0,5| \times \sigma(X) = 0,5 \times 2,4 = 1,2$$

- (c) L'application $t \mapsto -0,5t + 20$ est strictement décroissante car son coefficient directeur est négatif. Par conséquent, elle renverse l'ordre des données. Les plus petites notes initiales deviennent les plus grandes notes transformées et vice-versa. Les rôles des quartiles s'échangent donc :

- $Q_1(Z) = -0,5 \times Q_3(X) + 20 = -0,5 \times 11,5 + 20 = -5,75 + 20 = 14,25$
- $Q_3(Z) = -0,5 \times Q_1(X) + 20 = -0,5 \times 7,5 + 20 = -3,75 + 20 = 16,25$

Exercice 3 : Fusion de populations et formule de König-Huygens

1. Analyse globale de position

- (a) L'effectif total de la population fusionnée est $N = N_1 + N_2 = 60 + 40 = 100$. La moyenne globale $\bar{x}$ est donnée par la moyenne pondérée des moyennes de chaque groupe :

$$\bar{x} = \frac{N_1 \bar{x}_1 + N_2 \bar{x}_2}{N_1 + N_2} = \frac{60 \times 25 + 40 \times 35}{100} = \frac{1500 + 1400}{100} = \frac{2900}{100} = 29 \text{ min}$$

- (b) La moyenne arithmétique simple de $\bar{x}_1$ et $\bar{x}_2$ vaut $\frac{25+35}{2} = 30$ min. La moyenne globale (29 min) n'est pas égale à cette moyenne simple car les deux sous-populations possèdent des effectifs différents ($N_1 \neq N_2$). La formule de la moyenne globale montre qu'il s'agit d'un barycentre où chaque sous-population est pondérée par son effectif (le groupe A, plus nombreux, « attire » légitimement la moyenne globale vers sa propre moyenne de 25 min).

2. Analyse globale de dispersion

- (a) D'après la formule de König-Huygens appliquée au Groupe A, on a $V_1 = M_A - \bar{x}_1^2$, soit $\sigma_1^2 = M_A - \bar{x}_1^2$. On en isole la moyenne des carrés M_A :

$$M_A = \sigma_1^2 + \bar{x}_1^2 = 4^2 + 25^2 = 16 + 625 = 641$$

- (b) De la même manière pour le Groupe B :

$$M_B = \sigma_2^2 + \bar{x}_2^2 = 6^2 + 35^2 = 36 + 1225 = 1261$$

- (c) La moyenne des carrés pour la population totale, notée M_{tot} , s'obtient en effectuant la moyenne pondérée des moyennes des carrés de chaque sous-population (car la somme totale des carrés est la somme des carrés du Groupe A et du Groupe B) :

$$M_{\text{tot}} = \frac{N_1 M_A + N_2 M_B}{N_1 + N_2} = \frac{60 \times 641 + 40 \times 1261}{100}$$

$$M_{\text{tot}} = \frac{38460 + 50440}{100} = \frac{88900}{100} = 889$$

- (d) Appliquons de nouveau la formule de König-Huygens sur la population globale pour déterminer la variance globale V :

$$V = M_{\text{tot}} - \bar{x}^2 = 889 - 29^2$$

Or $29^2 = 841$. Donc :

$$V = 889 - 841 = 48$$

L'écart-type global σ est la racine carrée de la variance globale :

$$\sigma = \sqrt{V} = \sqrt{48} = 4\sqrt{3} \approx 6,93 \text{ min}$$

Commentaire : On remarque que l'écart-type global ($\sigma \approx 6,93$ min) est strictement supérieur à σ_1 (4 min) et à σ_2 (6 min). Cela s'explique par le fait que la dispersion globale prend en compte non seulement la dispersion interne à chaque groupe (variabilité intra-classe), mais s'y ajoute l'écart entre les moyennes des deux groupes (variabilité inter-classe, due au décalage important entre 25 min et 35 min).