

Chapitre 1 : Séries statistique à une variable

Ce chapitre est consacré à l'étude des séries statistiques quantitatives à une variable. Nous allons introduire les principales caractéristiques de position et de dispersion qui permettent de résumer et d'analyser les données d'une série statistique.

I Définitions et notations

Définition : Soit Ω une population finie de cardinal $N \in \mathbb{N}^*$. On appelle **série statistique quantitative à une variable** la donnée d'un N -uplet $(t_1, t_2, \dots, t_N) \in \mathbb{R}^N$ représentant les valeurs d'un caractère mesuré sur les N individus de la population.

Vocabulaire : On appelle **population** l'ensemble des **individus** sur lesquels on réalise une étude statistique. Un **caractère** est une propriété ou une mesure que l'on observe sur les individus de la population.

Remarque : En pratique, plusieurs individus peuvent présenter le même caractère. On préfère donc condenser l'information en regroupant les valeurs distinctes.

Définition : Soit Ω une population finie de cardinal $N \in \mathbb{N}^*$. On appelle **série statistique qualitative à une variable** la donnée d'un N -uplet $(t_1, t_2, \dots, t_N) \in E^N$ où E est un ensemble fini de modalités qualitatives.

Note de rédaction : Ce type de série ne semble pas figurer au programme du CAPES, mais il est important de le mentionner pour la complétude du cours et la cohérence avec les programmes du lycée.

Définition : Soit $\{x_1, x_2, \dots, x_k\}$ l'ensemble des valeurs distinctes de la série, ordonnées de telle sorte que $x_1 < x_2 < \dots < x_k$ (où $k \leq N$).

- L'**effectif** n_i associé à la valeur x_i est le nombre de fois où cette valeur apparaît dans le N -uplet initial. Il vérifie la relation :

$$\sum_{i=1}^k n_i = N$$

- La **fréquence** f_i associée à la valeur x_i est le rapport :

$$f_i = \frac{n_i}{N}$$

Elle vérifie les propriétés $f_i \in [0; 1]$ et $\sum_{i=1}^k f_i = 1$.

La série statistique est alors entièrement définie par l'ensemble des couples (x_i, n_i) ou (x_i, f_i) pour $i \in \{1, \dots, k\}$.

Exemple : Considérons les notes obtenues (*le caractère*) par un échantillon de $N = 5$ élèves à un examen : 10, 12, 20, 12, 12. Ici, la population Ω est l'ensemble des 5 élèves. Le nombre de valeurs distinctes est $k = 3$. On ordonne et on organise ces données sous forme de tableau :

Valeur distincte (x_i)	10	12	20
Effectif (n_i)	1	3	1
Fréquence (f_i)	0,2	0,6	0,2

On vérifie bien que :

- L'effectif total est $N = 1 + 3 + 1 = 5$.
- La somme des fréquences est $\sum f_i = 0,2 + 0,6 + 0,2 = 1$.

Exemple : Considérons les couleurs préférées (*le caractère*) d'un échantillon de $N = 10$ personnes : rouge, bleu, rouge, vert, bleu, rouge, vert, rouge, bleu, vert. Ici, la population Ω est l'ensemble des 10 personnes. Le nombre de valeurs distinctes est $k = 3$.

On ordonne et on organise ces données sous forme de tableau :

Valeur distincte (x_i)	Rouge	Bleu	Vert
Effectif (n_i)	4	3	3
Fréquence (f_i)	0,4	0,3	0,3

On vérifie bien que :

- L'effectif total est $N = 4 + 3 + 3 = 10$.
- La somme des fréquences est $\sum f_i = 0,4 + 0,3 + 0,3 = 1$.

II Caractéristiques de position

A Mode d'une série statistique

Définition : On appelle **mode** de la série statistique **quantitative ou qualitative** la valeur x_i qui correspond à l'effectif n_i (ou à la fréquence f_i) le plus grand.

Vocabulaire : On dit d'une série qu'elle est **unimodale** si elle admet un mode unique, **bimodale** si elle admet exactement deux modes, et **multimodale** si elle admet trois modes ou plus.

Exemple : Considérons la série statistique suivante : 1, 2, 2, 3, 4. Le mode de cette série est 2 car c'est la valeur qui apparaît le plus fréquemment (deux fois). Cette série est unimodale.

B Moyenne d'une série statistique

Définition : Soit une série statistique **quantitative** définie par les couples (x_i, n_i) ou (x_i, f_i) pour $i \in \{1, \dots, k\}$. On appelle **moyenne** de la série statistique, notée $\bar{x}$, le réel défini par :

$$\bar{x} = \frac{1}{N} \sum_{i=1}^k n_i x_i = \sum_{i=1}^k f_i x_i$$

Propriété :

1. **Linéarité (ou barycentre) :** La moyenne de la somme de deux séries est la somme des moyennes.
2. **Moyenne globale :** Soient deux sous-populations disjointes de tailles N_1 et N_2 , de moyennes respectives $\bar{x}_1$ et $\bar{x}_2$. La moyenne $\bar{x}$ de la population totale ($N = N_1 + N_2$) est donnée par :

$$\bar{x} = \frac{N_1 \bar{x}_1 + N_2 \bar{x}_2}{N_1 + N_2}$$

Théorème : Moindre carré

La moyenne $\bar{x}$ est l'unique réel θ qui minimise la fonction $g : \theta \mapsto \sum_{i=1}^k n_i (x_i - \theta)^2$, avec k le nombre de valeurs distinctes de la série statistique.

Preuve :

La fonction g est une fonction polynomiale du second degré en θ . Développons l'expression :

$$g(\theta) = \sum_{i=1}^k n_i (x_i^2 - 2\theta x_i + \theta^2) = \sum_{i=1}^k n_i x_i^2 - 2\theta \sum_{i=1}^k n_i x_i + \theta^2 \sum_{i=1}^k n_i$$

En utilisant le fait que $\sum_{i=1}^k n_i = N$ et $\sum_{i=1}^k n_i x_i = N\bar{x}$, on obtient :

$$g(\theta) = \sum_{i=1}^k n_i x_i^2 - 2\theta(N\bar{x}) + N\theta^2$$

g est de la forme $A\theta^2 + B\theta + C$ avec $A = N > 0$. Elle admet donc un minimum unique en :

$$\theta = -\frac{B}{2A} = -\frac{-2N\bar{x}}{2N} = \bar{x}$$

La fonction g atteint bien son minimum global et unique lorsque $\theta = \bar{x}$.

Remarque : Le $(x_i - \theta)^2$ donne l'intuition : on essaie de trouver le point (*i.e.* la moyenne) le plus proche de toutes les valeurs de la série, en minimisant la somme des carrés des écarts.

C Médiane d'une série statistique

Définition : On appelle **médiane** de la série statistique **quantitative** tout réel M_e vérifiant les deux conditions suivantes :

- Au moins 50 % des individus ont une valeur inférieure ou égale à M_e .
- Au moins 50 % des individus ont une valeur supérieure ou égale à M_e .

Exemple : Considérons la série statistique suivante : 1, 2, 3, 4, 5. La médiane de cette série est $M_e = 3$ car :

- Les valeurs 1 et 2 sont inférieures ou égales à 3, soit 40 % des données.
- Les valeurs 4 et 5 sont supérieures ou égales à 3, soit également 40 % des données.

Ainsi, la médiane est le point d'équilibre qui sépare la série en deux parties égales en termes de nombre d'individus.

Propriété pratique de calcul :

On considère les valeurs de la série sous leur forme initiale de N -uplet ordonné par ordre croissant : $t_{(1)} \leq t_{(2)} \leq \dots \leq t_{(N)}$.

- Si N est impair, il existe $p \in \mathbb{N}$ tel que $N = 2p + 1$. La médiane est unique et vaut :

$$M_e = t_{(p+1)}$$

- Si N est pair, il existe $p \in \mathbb{N}^*$ tel que $N = 2p$. Tout réel de l'intervalle $[t_{(p)}; t_{(p+1)}]$ est une médiane. Par convention, on choisit le milieu de cet intervalle :

$$M_e = \frac{t_{(p)} + t_{(p+1)}}{2}$$

Théorème : Optimisation en valeur absolue

La médiane M_e (ou tout réel médian au sens de la définition si N est pair) est un réel θ qui minimise la fonction $h : \theta \mapsto \sum_{i=1}^k n_i |x_i - \theta|$, où k est le nombre de valeurs distinctes de la série statistique.

Preuve (dans le cas où toutes les données sont distinctes, $k = N$) :

La fonction h est continue, affine par morceaux et convexe. Étudions son taux d'accroissement (sa dérivée à droite) sur chaque intervalle $[x_j; x_{j+1}]$.

Pour $\theta \notin \{x_1, \dots, x_N\}$, la fonction h est dérivable et sa dérivée vaut :

$$h'(\theta) = \sum_{i=1}^N \text{sgn}(\theta - x_i) = \text{card}(\{i / x_i < \theta\}) - \text{card}(\{i / x_i > \theta\})$$

- Si $\theta < M_e$, le nombre de valeurs supérieures à θ est strictement plus grand que le nombre de valeurs inférieures : $h'(\theta) < 0$, la fonction décroît.
- Si $\theta > M_e$, le nombre de valeurs inférieures à θ est strictement plus grand que le nombre de valeurs supérieures : $h'(\theta) > 0$, la fonction croît.

Par conséquent, le minimum global de h est atteint au point de bascule, qui correspond précisément aux critères de la médiane M_e .

III Caractéristiques de dispersion

Les caractéristiques suivantes sont définies uniquement pour les séries statistiques quantitatives, car elles mesurent la dispersion des données autour d'une valeur centrale (comme la moyenne ou la médiane).

A Étendue

Définition : On appelle **étendue** d'une série statistique **quantitative**, notée E , la différence entre la plus grande valeur et la plus petite valeur prises par le caractère :

$$E = x_k - x_1$$

B Quartiles et écart interquartile

Définition : On appelle **premier quartile**, noté Q_1 , le plus petit élément de la série tel qu'au moins 25 % des données soient inférieures ou égales à Q_1 .

On appelle **troisième quartile**, noté Q_3 , le plus petit élément de la série tel qu'au moins 75 % des données soient inférieures ou égales à Q_3 .

Propriété pratique de calcul :

On considère les valeurs de la série ordonnées par ordre croissant : $t_{(1)} \leq t_{(2)} \leq \dots \leq t_{(N)}$.

- Q_1 correspond à la valeur d'indice $[0, 25N]$ (où $[\cdot]$ désigne la partie entière supérieure).
- Q_3 correspond à la valeur d'indice $[0, 75N]$.

Définition : On appelle **écart interquartile** le réel positif défini par $Q_3 - Q_1$. Il mesure la dispersion des 50 % centraux de la population.

 **Exemple :** On considère la durée du règne des 7 derniers papes de l'Église catholique :

François	Benoît XVI	Jean-Paul II	Jean-Paul I	Paul VI	Jean XXIII	Pie XII
12,1 ans	7,8 ans	26,5 ans	33 jours ($\approx 0,1$ an)	15,1 ans	4,6 ans	19,6 ans

En ordonnant ces $N = 7$ durées de règne par ordre croissant, on obtient la série brute suivante (exprimée en années) :

0,1 ; 4,6 ; 7,8 ; 12,1 ; 15,1 ; 19,6 ; 26,5

Déterminons les caractéristiques de dispersion de cette série :

- **Premier quartile Q_1 :** Il correspond à la valeur d'indice $[0, 25 \times 7] = [1, 75] = 2$.
La deuxième valeur de la série ordonnée est $Q_1 = 4,6$ ans (durée du règne de Jean XXIII).
- **Troisième quartile Q_3 :** Il correspond à la valeur d'indice $[0, 75 \times 7] = [5, 25] = 6$.
La sixième valeur de la série ordonnée est $Q_3 = 19,6$ ans (durée du règne de Pie XII).
- **Écart interquartile :** Il est égal à $Q_3 - Q_1 = 19,6 - 4,6 = 15$ ans.

L'écart interquartile indique que la moitié centrale des durées de ces pontificats s'étend sur une période de 15 ans.

Remarque : L'étude de cette série met parfaitement en évidence la robustesse de l'écart interquartile face aux valeurs extrêmes, contrairement à l'étendue.

C Diagramme en boîte à moustaches

Définition : Le **diagramme en boîte à moustaches** (ou boîte à pattes, ou *boxplot*) est une représentation graphique résumant visuellement la distribution d'une série statistique quantitative à l'aide de cinq caractéristiques numériques appelées **les cinq nombres de synthèse** :

- La valeur minimale (x_1) ;
- Le premier quartile (Q_1) ;
- La médiane (M_e) ;
- Le troisième quartile (Q_3) ;
- La valeur maximale (x_k).


Exemple : Reprenons la série statistique du rectangle central des durées de règne des 7 derniers papes (triée par ordre croissant) :

0,1 ; 4,6 ; 7,8 ; 12,1 ; 15,1 ; 19,6 ; 26,5

Les cinq nombres de synthèse calculés précédemment sont :

- Min = 0,1 an
- $Q_1 = 4,6$ ans
- $M_e = 12,1$ ans (valeur d'indice 4)
- $Q_3 = 19,6$ ans
- Max = 26,5 ans

Le diagramme se construit de la manière suivante : un rectangle (la boîte) s'étend de Q_1 à Q_3 (sa largeur vaut l'écart interquartile). Une ligne verticale marque la position de la médiane M_e . Les "moustaches" s'étendent de part et d'autre de la boîte jusqu'aux valeurs minimale et maximale.



On observe graphiquement l'asymétrie de la distribution : la moitié inférieure des données (entre Min et M_e) est plus regroupée que la moitié supérieure (entre M_e et Max).

D Variance et écart-type

Définition : Soit une série statistique définie par les couples (x_i, n_i) pour $i \in \{1, \dots, k\}$ et de moyenne $\bar{x}$.

- On appelle **variance** de la série statistique, notée V , le réel positif défini par la moyenne des carrés des écarts à la moyenne :

$$V = \frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{x})^2 = \sum_{i=1}^k f_i (x_i - \bar{x})^2$$

- On appelle **écart-type** de la série statistique, noté σ , la racine carrée de sa variance :

$$\sigma = \sqrt{V}$$

Remarque : L'écart-type est une mesure de dispersion qui a la même unité que les données, contrairement à la variance qui est exprimée en unités au carré.

Théorème : Formule de König-Huygens

La variance V d'une série statistique est égale à la moyenne des carrés des valeurs moins le carré de leur moyenne :

$$V = \left(\frac{1}{N} \sum_{i=1}^k n_i x_i^2 \right) - \bar{x}^2 = \left(\sum_{i=1}^k f_i x_i^2 \right) - \bar{x}^2$$

Preuve :

Développons le terme général sous la somme de la définition de la variance :

$$V = \frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{x})^2 = \frac{1}{N} \sum_{i=1}^k n_i (x_i^2 - 2\bar{x}x_i + \bar{x}^2)$$

Par linéarité de la somme, on peut séparer l'expression en trois sommations distinctes :

$$V = \frac{1}{N} \sum_{i=1}^k n_i x_i^2 - \frac{1}{N} \sum_{i=1}^k 2\bar{x}n_i x_i + \frac{1}{N} \sum_{i=1}^k n_i \bar{x}^2$$

Dans la deuxième et la troisième somme, le terme $\bar{x}$ ne dépend pas de l'indice de sommation i , on peut donc le mettre en facteur :

$$V = \left(\frac{1}{N} \sum_{i=1}^k n_i x_i^2 \right) - 2\bar{x} \left(\frac{1}{N} \sum_{i=1}^k n_i x_i \right) + \bar{x}^2 \left(\frac{1}{N} \sum_{i=1}^k n_i \right)$$

Or, par définition de la moyenne et de l'effectif total, on sait que :

$$\frac{1}{N} \sum_{i=1}^k n_i x_i = \bar{x} \quad \text{et} \quad \frac{1}{N} \sum_{i=1}^k n_i = \frac{N}{N} = 1$$

En substituant ces relations dans l'égalité, on obtient :

$$V = \left(\frac{1}{N} \sum_{i=1}^k n_i x_i^2 \right) - 2\bar{x}(\bar{x}) + \bar{x}^2(1)$$

$$V = \left(\frac{1}{N} \sum_{i=1}^k n_i x_i^2 \right) - 2\bar{x}^2 + \bar{x}^2$$

$$V = \left(\frac{1}{N} \sum_{i=1}^k n_i x_i^2 \right) - \bar{x}^2$$

Ce qui démontre la formule de König-Huygens. □

Exemple : Considérons la série statistique suivante : 1, 2, 3, 4, 5. Calculons sa variance et son écart-type.

- La moyenne de la série est $\bar{x} = \frac{1+2+3+4+5}{5} = 3$.
- La moyenne des carrés des valeurs est $\frac{1^2+2^2+3^2+4^2+5^2}{5} = \frac{55}{5} = 11$.
- En appliquant la formule de König-Huygens, on trouve :

$$V = 11 - 3^2 = 11 - 9 = 2$$

$$\sigma = \sqrt{V} = \sqrt{2} \approx 1,41$$

Ainsi, la variance de cette série est 2 et son écart-type est d'environ 1,41.

IV Transformation affine

Définition : Soit une série statistique quantitative définie par les couples (x_i, n_i) ou (x_i, f_i) pour $i \in \{1, \dots, k\}$. Soient $a \in \mathbb{R}^*$ et $b \in \mathbb{R}$. La série statistique transformée par l'application affine $T : x \mapsto ax + b$ est définie par les couples (y_i, n_i) ou (y_i, f_i) où $y_i = ax_i + b$ pour chaque i .

Propriété : Transformation affine de la moyenne

Soit une série statistique quantitative et sa transformation affine par $T : x \mapsto ax + b$. La moyenne de la série transformée, notée $\bar{y}$, est donnée par :

$$\bar{y} = a\bar{x} + b$$

Propriété : Effet d'une transformation affine sur les indicateurs

Soit une série statistique quantitative initiale et sa transformation affine par $T : x \mapsto ax + b$ avec $a \in \mathbb{R}^*$ et $b \in \mathbb{R}$.

1. **Indicateurs de position :** La médiane et les quartiles subissent la même transformation affine si $a > 0$. De manière générale :

- Si $a > 0$, alors $M_e(Y) = aM_e(X) + b$, $Q_1(Y) = aQ_1(X) + b$ et $Q_3(Y) = aQ_3(X) + b$.
- Si $a < 0$, l'ordre des données étant inversé, les rôles des quartiles s'échangent : $Q_1(Y) = aQ_3(X) + b$ et $Q_3(Y) = aQ_1(X) + b$.

2. **Indicateurs de dispersion :** Les indicateurs de dispersion sont insensibles à la translation (b) et sont multipliés par la valeur absolue ou le carré du coefficient multiplicateur (a) :

- Étendue : $E(Y) = |a|E(X)$
- Écart interquartile : $I_Q(Y) = |a|I_Q(X)$
- Variance : $V(Y) = a^2V(X)$
- Écart-type : $\sigma(Y) = |a|\sigma(X)$

Preuve pour la variance et l'écart-type :

Par définition, la variance de la série transformée Y est :

$$V(Y) = \frac{1}{N} \sum_{i=1}^k n_i (y_i - \bar{y})^2$$

En substituant $y_i = ax_i + b$ et $\bar{y} = a\bar{x} + b$, on obtient :

$$V(Y) = \frac{1}{N} \sum_{i=1}^k n_i [(ax_i + b) - (a\bar{x} + b)]^2$$

Les constantes b s'annulent à l'intérieur de la parenthèse :

$$V(Y) = \frac{1}{N} \sum_{i=1}^k n_i [a(x_i - \bar{x})]^2 = \frac{1}{N} \sum_{i=1}^k n_i a^2 (x_i - \bar{x})^2$$

Par linéarité de la sommation, on peut sortir la constante a^2 de la somme :

$$V(Y) = a^2 \left(\frac{1}{N} \sum_{i=1}^k n_i (x_i - \bar{x})^2 \right) = a^2 V(X)$$

En passant à la racine carrée pour l'écart-type, puisque $\sqrt{a^2} = |a|$ pour tout réel a , on en déduit :

$$\sigma(Y) = \sqrt{V(Y)} = \sqrt{a^2 V(X)} = |a| \sqrt{V(X)} = |a| \sigma(X) \square$$

i Remarque : Le fait que $\sigma(Y) = |a| \sigma(X)$ montre bien qu'une dispersion est une grandeur géométrique toujours positive. Une translation des données (b) ne modifie pas l'écartement mutuel des points, ce qui explique pourquoi b n'intervient pas dans les formules de dispersion.

Contents

I	Définitions et notations	1
II	Caractéristiques de position	2
A	Mode d'une série statistique	2
B	Moyenne d'une série statistique	2
C	Médiane d'une série statistique	3
III	Caractéristiques de dispersion	4
A	Étendue	4
B	Quartiles et écart interquartile	4
C	Diagramme en boîte à moustaches	5
D	Variance et écart-type	6
IV	Transformation affine	7